

Unicid Universidade Cidade De São Paulo

Ciência da Computação

**ANÁLISE DE VIÉS ALGORÍTMICO E CASOS DE BORDA EM VISÃO
COMPUTACIONAL**

NOME: Alexandro de Araujo Junior

PROFESSOR: Diego Marques de Carvalho


DISCIPLINA: Fundamentos de Inteligência Artificial

São Paulo - SP

2026

Composição do Dataset de Treinamento

As imagens abaixo representam as amostras utilizadas para alimentar o modelo. A escolha deliberada desses conjuntos visa criar uma polarização visual clara entre as duas categorias.



Parte 1: Laboratório de Classificação Visual




Figura 1: Teste com objeto inanimado (Bebê Reborn). Análise: O modelo apresenta uma classificação dividida: 63% Criança e 37% Adulto. O erro ocorre porque a IA não reconhece a "humanidade", mas processa texturas artificiais e sombreamentos do boneco que o sistema associa estatisticamente a traços de envelhecimento presentes no grupo de adultos.




Figura 2: Teste com jovem em faixa etária não treinada. Análise: O sistema indica 100% de confiança para a classe "Adultos". Por não encontrar os traços infantis

específicos do treinamento (como proporções faciais de bebês), o algoritmo força a classificação para a única outra opção disponível, ignorando a realidade da idade do indivíduo devido ao "vácuo" no treinamento.




Figura 3: Teste de generalização incorreta. Análise: Neste caso, o modelo aponta 99% para a classe "Crianças". A ausência de sinais claros de envelhecimento (rugas ou marcas de expressão do grupo 30+) faz com que a máquina "chute" a categoria oposta, demonstrando a instabilidade de um modelo alimentado com dados polarizados e incompletos.

Parte 2: Memorial de Impacto e Ética

Mecanismo do Viés

A seleção restrita de dados distorce o funcionamento do algoritmo porque o modelo aprende apenas padrões limitados presentes no conjunto de treinamento. Quando o sistema recebe imagens semelhantes entre si, ele associa características superficiais — como roupas, aparência ou idade — às categorias definidas. Dessa forma, o algoritmo constrói relações estatísticas simplificadas e passa a interpretar esses padrões como regra geral. O modelo não compreende o contexto humano; ele apenas replica as correlações existentes nos dados fornecidos. Assim, a ausência de diversidade no dataset produz um sistema que interpreta a realidade de maneira incompleta e gera classificações incorretas.

Consequência Social

Quando um sistema automatizado classifica pessoas de forma incorreta, ele afeta diretamente a identidade e a percepção social do indivíduo. A pessoa classificada de maneira equivocada pode sentir frustração, exclusão ou constrangimento ao perceber que um sistema tecnológico não reconhece corretamente suas características. Em ambientes profissionais, esse tipo de erro também pode gerar impactos mais sérios, como decisões injustas em processos de seleção, avaliação ou acesso a serviços. Dessa forma, o viés algorítmico reforça estereótipos e amplia desigualdades existentes na sociedade.

Ação Mitigadora

A abordagem de *Human-in-the-loop* introduz supervisão humana no processo de desenvolvimento do modelo. Especialistas revisam o conjunto de dados, analisam possíveis lacunas e incluem exemplos diversos antes da implementação do sistema. Essa intervenção garante maior representatividade no treinamento e reduz a probabilidade de decisões enviesadas. Além disso, a revisão contínua permite identificar erros, ajustar o modelo e assegurar que o sistema opere com maior justiça e responsabilidade social.

Acesso ao Modelo

Para fins de verificação e teste das inferências apresentadas neste relatório, o modelo treinado pode ser acessado através do link abaixo:

<https://teachablemachine.withgoogle.com/models/YtZBP6wNE/>